# Orchestration et automatisation

**ESIR** 

Djob Mvondo

# Déploiement ???

**Automatisation** 

Choix des nœuds

En continu

Surveiller

Automatiser l'installation des dépendances, des binaires, et le paramétrage de l'application/module.

# Déploiement ???


Taux utilisation ressources

Automatisation

Choix des nœuds


En continu

Surveiller



Quel serveur choisir? (Bin packing problem)


- ☐ Placer le module en fonction des quantités de mémoire et CPU
- ☐ Optimiser les ressources disponible (éviter les pitholes)
- ☐ Les unités d'isolations n'utilisent pas forcément toutes les ressources




Quel serveur choisir? (Bin packing problem)

Taux utilisation

EOLAS CLOUD --- mean CPU usage of 10% --- 4 months observations



Providing SLOs for Resource-Harvesting VMs in Cloud Platforms – OSDI'20



#### Memory-Harvesting VMs in Cloud Platforms- ASPLOS'22




Figure 1: Allocated resources per server in increasing order. There is room for harvesting both cores and memory.

#### Memory-Harvesting VMs in Cloud Platforms- ASPLOS'22




Figure 2: Resource changes per hour at each server over all hours. 82.5% of the hours involve no VM events, and in 86.5% of them there are no VM arrivals.





Figure 3: Core and memory allocation changes. Positive values mean VM arrivals. 90% of the VM creations involve 8 cores or fewer and 32 GB of memory or less.

### Rôle du consolidateur



Minimise le nombre de machines physiques

Eteint les machines physiques

Exploite la migration à chaud (faut minimiser l'impact)


#### Exploiter la mémoire non-utilisée




Pas de mémoire disponible à priori

Noyau système de virtualisation	Une VM	Une VM	Une VM	Une VM
------------------------------------	--------	--------	--------	--------


Exploiter la mémoire non-utilisée




Exploiter la mémoire non-utilisée – Principe du ballooning



Exploiter la mémoire non-utilisée – Principe du ballooning



Exploiter la mémoire non-utilisée – Principe du ballooning



# Déploiement ???


Taux utilisation ressources

Automatisation

Choix des nœuds

En continu

Surveiller






Observer les modules et déclencher les actions correspondantes



# Automatisation — docker-compose

docker-compose permet l'automatisation le déploiement d'une application multi-container --- en automatisant les différentes configuration à effectuer



# Déploiement ???


Taux utilisation ressources

Automatisation

Choix des nœuds

En continu

Surveiller




Quel serveur choisir? (Bin packing problem)

#### Orchestrateur

L'orchestrateur se charge de la gestion des unités d'isolations.


Elle gère le placement des unités sur les différents nœuds en fonction du taux d'utilisation et surveille les unités pour assurer leur disponibilités.



#### Orchestrateur - Containers

Plusieurs orchestrateurs opensource et propriétaires existent pour les containers, Docker Swarm, Openshift, Kubernetes, Mesos, Nomad, Rancher, etc.

Nous allons illustrer les concepts d'un orchestrateur avec **Kubernetes**, mais tous reposent sur les même principes.



Worker Node Worker Node Pod Pod Pod Pod container Docker runtime Docker runtime kube-proxy kubelet kube-proxy kubelet kubeadm scheduling **APIs** networking etcd monitoring Input config kubectl Master node (yaml format)

Kubernetes repose sur une architecture master/workers.

Les nœuds workers possède l'environnement pour l'exécution des containers.

Le nœud master communique avec les workers pour surveiller l'état des containers grâce au service **kubelet** et persiste les données sur **etcd**.

Les nœuds workers créent des containers dans une abstraction appelé **pods** qui symbolise un groupe de containers qui réalisent un objectif précis.

L'isolation réseau est assuré par le composant kube-proxy

#### On Ubuntu

sudo apt-get update

sudo apt-get install -y apt-transport-https ca-certificates curl

sudo curl -fsSLo /usr/share/keyrings/kubernetes-archive-keyring.gpg
https://packages.cloud.google.com/apt/doc/apt-key.gpg

echo "deb [signed-by=/usr/share/keyrings/kubernetesarchive-keyring.gpg] https://apt.kubernetes.io/ kubernetes-xenial main" | sudo tee /etc/apt/sources.list.d/kubernetes.list

sudo apt-get update sudo apt-get install -y kubelet kubeadm kubectl sudo apt-mark hold kubelet kubeadm kubectl

#### On Windows (kubectl, kubelet)

Installer docker-desktop puis aller dans les paramètres de Docker et assurer vous que Kubernetes est activé (diode verte)

Kubeadm ne supporte pas les hôtes Windows mais les worker peuvent tourner sous Windows

Tester votre installation avec :

kubectl –version kubectl get all

Format du fichier de configuration

Télécharger le fichier deployment.yaml à l'adresse suivante :

https://github.com/djobiii2078/cloud\_course\_reso urces/blob/main/deployment.yaml

Pouvez-vous expliquer ce qu'il décrit ?

#### Déploiement continu

```
minReadySeconds: 10
strategy:
   rollingUpdate:
      maxSurge: 1
      maxUnavailable: 0
   type: RollingUpdate
```

Définit la stratégie de mise à jour pour notre déploiement.

MaxSurge conditionne le nombre de containers à instancier lors du passage à l'échelle.

Mettez à jour le déploiement :

kubectl apply -f deployment.yaml

Qu'observez-vous ? Essayer d'arreter un de vos containers et décrivez ce qui se passe.

#### Déploiement continu

```
spec:
    containers:
    - name: bb-site:v2
    image: getting-started
```

Le fichier peut être mis à jour pour faire évoluer l'architecture.

Kubernetes redeploie les composants modifiés pour s'ajuster aux nouvelles directives.

Mettez à jour le déploiement :

kubectl apply –f deployment.yaml

Vérifier si l'image de vos containers ont bien évolué ...

Surveillance (Monitoring): Kubernetes dashboard

